

LLM Wiki

Guida all'Installazione


Wiki personale con **OCR automatico** e **chat AI** — completamente offline.

Cos'è LLM Wiki?

- Drag & drop documenti PDF, immagini, testo
- OCR automatico: estrae testo embedded o scansionato
- Summarizzazione AI: genera pagine wiki strutturate
- Chat con RAG: fai domande sui tuoi documenti
- 100% offline: nessun dato esce dalla tua macchina

```
raw/documento.pdf → OCR → LLM → wiki/sources/2025-01-01_documento.md
                        ↓
                    Chat con BM25 + Ollama
```

Architettura



Prerequisiti

Componente	Versione	Come installare
Python	≥ 3.11	<code>winget install Python.Python.3.11</code>
Ollama	qualsiasi	<code>winget install Ollama.Ollama</code>
Tesseract	qualsiasi	<code>winget install UB-Mannheim.TesseractOCR</code>

Tesseract è **opzionale** — serve solo per PDF scansionati e immagini.
PDF con testo embedded funzionano senza.

Scegli il modello in base all'hardware

RAM disponibile	GPU VRAM	Tag Ollama	Dimensione
qualsiasi	≥ 12 GB	qwen3:32b-a3b	~20 GB
qualsiasi	≥ 8 GB	qwen3:14b	~9 GB
≤ 4 GB	—	qwen3:1.7b	~1.5 GB
4–6 GB	—	qwen3:4b	~2.6 GB
6–10 GB (velocità)	—	qwen3:8b	~5.2 GB
10–14 GB	—	qwen3:14b	~9.3 GB
14–20 GB (velocità)	—	qwen3:30b-a3b	~20 GB
> 20 GB	—	qwen3:32b	~20 GB

Step 1 — Installa Ollama

Windows:

```
winget install Ollama.Ollama  
# riavvia il terminale dopo l'installazione  
ollama --version
```

Linux / macOS:

```
curl -fsSL https://ollama.com/install.sh | sh
```

Verifica:

```
Invoke-WebRequest -Uri "http://localhost:11434/api/tags"  
# atteso: JSON con chiave "models"
```

Step 2 — Scarica il modello

```
# Sostituisci con il tag scelto dalla tabella  
ollama pull qwen3:14b
```

Tempo stimato:

- Modelli piccoli (1.7b–8b): **2–5 minuti**
- Modelli grandi (14b–32b): **10–40 minuti**

Se `ollama pull` fallisce con 404:

```
ollama search qwen3    # cerca tag disponibili
```

Step 3 — Installa dipendenze Python

```
pip install -r backend/requirements.txt
```

Dipendenze principali:

Pacchetto	Scopo
<code>fastapi</code> + <code>uvicorn</code>	Server API
<code>pypdfium2</code>	Estrazione testo PDF
<code>pytesseract</code> + <code>Pillow</code>	OCR immagini
<code>rank-bm25</code>	Ricerca full-text
<code>httpx</code>	Chiamate a Ollama
<code>python-frontmatter</code>	Parsing YAML wiki

Step 4 — Configura .env

Crea il file `.env` nella root del progetto:

```
OLLAMA_URL=http://localhost:11434  
MODEL_NAME=qwen3:14b  
OCR_DEVICE=cpu  
RAW_DIR=raw  
WIKI_DIR=wiki
```

Se Tesseract non è nel PATH di sistema:

```
TESSERACT_CMD=C:\Program Files\Tesseract-OCR\tesseract.exe
```

Copia da `.env.example` come punto di partenza.

Step 5 — Avvia

Terminale 1 — avvia Ollama (se non parte in automatico):

```
ollama serve
```

Terminale 2 — avvia il backend:

```
uvicorn backend.main:app --reload
```

Oppure tutto-in-uno con il launcher:

```
python launcher.py
```

Apri il browser su <http://localhost:8000>

Verifica installazione

1. Ollama risponde e ha il modello

```
Invoke-RestMethod -Uri "http://localhost:11434/api/tags" | ConvertTo-Json
```

2. Test chat one-shot

```
$body = '{"model":"qwen3:14b","messages":[{"role":"user","content":"ciao"}],"stream":false}'
```

```
Invoke-RestMethod -Uri "http://localhost:11434/v1/chat/completions" `
  -Method Post -Body $body -ContentType "application/json"
```

3. Config Python OK

```
python -c "from backend.config import settings; print('OK:', settings.model_name)"
```

Installazione completata

Apri <http://localhost:8000> e:

1. Carica un documento — drag & drop nella sidebar
2. Attendi l'ingest — 10–30 min su CPU (visibile nel log panel)
3. Fai una domanda — la chat usa BM25 + Ollama per rispondere

Per la selezione guidata del modello e troubleshooting completo:

CLAUDE.md → sezione `/install`

| Avvia `/install` in Claude Code per l'installazione adattiva automatica